

数据预处理

5.1 数据重构：从“宽表”到“长表”

原始数据采用“宽格式” (Wide Format)，即每个评委在每一周的打分都作为独立的列存在（如 `Week 1 Judge 1`, `Week 1 Judge 2...`）。这种格式不利于时序分析和数学建模。

- **操作思路**：利用 MATLAB 的 `stack` 函数或 Python 的 `melt` 方法，将数据降维。
- **目标格式**：建立以“（赛季 - 周次 - 选手）”为唯一主键的面板数据（Panel Data）。
- **新结构**：[Season, Week, Celebrity_Name, Judge_Score_Raw, ...]
- **目的**：统一处理不同周次评委人数不一致（3 人或 4 人）的问题，使模型具有通用性。

5.2 文本挖掘：生命周期提取

选手的生存状态隐含在非结构化的 `Results` 文本列中（例如 "Eliminated Week 5"）。我们需要将其转化为可计算的数值变量。

- **正则表达式提取 (Regex)**:
 - 针对淘汰者：匹配模式 `(Eliminated|Withdrew).*Week(\d+)`，提取数字作为「淘汰周数 (Elimination Week)」。
 - 针对幸存者 (Winner/Runner-up)：若匹配失败且非空，标记其「淘汰周数」为 99（或该赛季最大周数），代表其存活至最后。
- **退赛处理 (Withdrew)**：识别包含 "Withdrew" 的记录，建立布尔变量「是否退赛 (IsWithdrew)」。在后续模型中，这些样本将不参与“基于分数的淘汰预测”，因为其离开是非技术原因。

5.3 核心特征构造：归一化与排名

这是本题建模最关键的一步。为了消除不同周次评委总分差异（如满分 30 vs 40）的影响，必须从“绝对分数”转向“相对份额”。

- **变量 1：评委平均分 (Judge Average Score)**

计算公式： $JudgeAvg = \frac{\sum_{i=1}^n Score_i}{n}$ （n 为当周有效打分评委数）

用途：仅用于 **数据可视化 (Visualization)**，直观展示选手水平波动。

- **变量 2：评委分占比 (Judge Score Share) —— 建模核心**

计算公式： $JudgeShare = \frac{\sum_{i=1}^n Score_i}{\sum_{all} \sum_{i=1}^n Score_i}$

其中 $\sum_{i=1}^n Score_i$ 是选手 x 在第 w 周获得的评委总分; $\sum_{all} \sum_{i=1}^n Score_i$ 是当周所有选手的评委总分之和。

用途: **线性规划 (Linear Programming)** 的输入系数。在百分比制投票规则下, 该变量直接决定了选手需要多少粉丝票才能存活。

- **变量 3: 当周排名 (Weekly Rank)**

对当周所有参赛者的 JudgeShare 进行降序排列, 计算「当周排名 (Rank)」。

用途: 用于对比“排名制”与“百分比制”的公平性分析。

5.4 缺失值与样本筛选策略

针对不同的分析目的, 采用分叉处理策略:

- **策略 A: 用于可视化 (Dataset for Visualization)**

保留被淘汰后的行, 并将得分填充为 NaN。

目的: 在 MATLAB 绘图 (plot) 时, NaN 会自动导致线条断开, 从而清晰地展示选手“何时离场”, 避免折线坠落至 0 的视觉误导。

- **策略 B: 用于数学模型 (Dataset for Modeling)**

严格剔除所有 NaN 行、得分均值为 0 的行 (未参赛) 以及已淘汰选手的后续记录。

目的: 保证线性规划求解器 (linprog) 和回归模型 (fitlm) 的输入矩阵是稠密且有效的。

5.5 辅助特征编码

为了完成 Task 4 (人口统计学分析), 需要将文本特征数值化。

- **行业分类 (Industry):** 将 Celebrity Industry 映射为大类 (如: 运动员 = 1, 演艺界 = 2, 真人秀 = 3, 其他 = 4)。
- **性别推断 (Gender):** (如果数据未提供) 可选择忽略或利用 Partner Name 进行辅助推断 (通常是异性搭档)。